

Mnohorozměrná analýza dat

Zápočtová úloha

Karolína Šustrová (459)

Popis dat a cíl analýzy

Pro vypracování úlohy byl použit dataset Boston dostupný v balíčku MASS. Dataset obsahuje sociálně-ekonomické a environmentální informace o 506 čtvrtích v Bostonu a jeho okolí. Cílovou proměnnou je medv, která udává mediánovou cenu nemovitostí v dolarech.


Cílem této úlohy bylo porovnat výkon dvou regresních modelů, klasického lineárního modelu a PCR (Principal Component Regression), a rozhodnout, který z nich lépe předpovídá proměnnou medv.

Průzkumná analýza a vizualizace


Na datech bylo nejprve provedena průzkumná analýza s grafickou vizualizací.

Histogram distribuce cílové proměnné medv ukázal, že rozložení je mírně levostranné, což znamená, že častější jsou nižší hodnoty cen nemovitostí.

Korelační analýzou bylo zjištěno, že největší negativní korelaci s cílovou proměnnou medv mají proměnné lstat (procento nižšího sociálního statusu) a ptratio (poměr studentů na učitele). Naopak nejvíce pozitivní korelaci má proměnná rm (průměrný počet pokojů).



Obrázek 1: Histogram cílové proměnné medv



Obrázek 2: Korelační matice

Klasická lineární regrese


Před použitím modelů byla data nejprve rozdělena na trénovací a testovací sadu v poměru 50/50 na základě náhodného rozdělení.

Lineární regresní model byl sestaven za použití všech dostupných prediktorů a natrénován na trénovací sadě dat. Jeho predikční schopnost byla následně ověřena na testovací množině pomocí metriky RMSE, která dosáhla hodnoty 4,63. Model také odhalil, že nejvýznamnější vliv na cílovou proměnnou medv mají proměnné lstat, rm, ptratio a nox. Zbylé prediktory ovlivňují medv méně a mohou být dokonce redundantní. Lineární regresní model dosáhl poměrně nízké chyby a ceny nemovitostí na základě testovací množiny odhadoval dobře.

Principal Component Regression (PCR)

PCR model kombinuje hlavní komponentovou analýzu (PCA) a lineární regresi. Redukuje dimenzionalitu dat transformací vstupních proměnných do ortogonálních komponent, na kterých následně provádí regresi. Je vhodnou metodou v případech, kdy mezi prediktory existuje silná kolinearita.

Model byl natrénován na standardizovaných datech s 10násobnou křížovou validací. Pro zjištění vhodného počtu komponent byl vytvořen graf závislosti RMSEP na počtu komponent. Ten ukázal výrazný pokles chyby při použití 6 komponent, které vysvětlily 85,55 % variability vstupních proměnných a 65,55 % variability cílové proměnné medv. RMSE na testovací množině s 6 komponentami dosáhlo hodnoty 4,88.



Obrázek 3: Validation plot – RMSE vs počet komponent

Porovnání modelů

Tabulka 1: Porovnání RMSE obou modelů

Model	RMSE na testovací množině
Lineární regrese	4,63
PCR s 6 komponentami	4,88

Z porovnání vyplívá, že klasická lineární regrese dosáhla nižšího RMSE na testovacích datech než PCR. I přesto, že PCR odstranilo korelace mezi prediktory a snížilo dimenzionalitu. To znamená, že klasická lineární regrese pro tento dataset byla přesnější a lépe predikovala cílovou proměnnou popisující mediánovou cenu nemovitostí.

Závěr

Cílem úlohy bylo srovnat dva regresní modely na datech z datasetu Boston. Jako efektivnější model se ukázala klasická lineární regrese, protože dosáhla nižší chyby a poskytla přímou interpretaci významnosti jednotlivých proměnných.

PCR by mohlo být užitečné pro dataset, který má silně korelované prediktory a hrozí tak přeučení modelu. V případě datasetu Boston však nebylo výhodnější.